Machine Learning para la Valuación Inmobiliaria: Caso de Estudio en Mérida, Yucatán

Gallareta, Gaspar A.

***Resumen*—Este trabajo desarrolla un modelo predictivo para estimar el precio de departamentos en Mérida, Yucatán, utilizando técnicas de aprendizaje automático. Se realizó un análisis exploratorio de datos para caracterizar la estructura del mercado. Posteriormente se estimaron modelos de regresión lineal (en niveles y logarítmica) y un modelo Random Forest. Los resultados muestran que la transformación logarítmica mejora la estabilidad estadística del modelo lineal, mientras que Random Forest captura adecuadamente relaciones no lineales presentes en el mercado inmobiliario.**

***Index Terms*—Valuación inmobiliaria, regresión lineal, Random Forest, aprendizaje automático, mercado inmobiliario.**

I. Introducción

La creciente dinámica del mercado inmobiliario en Mérida, Yucatán, se ha convertido en un tema de amplio interés tanto para inversionistas como para compradores finales. La oferta actual incluye una amplia variedad de inmuebles, tales como departamentos, casas y lotes residenciales, lo que ha generado una estructura de precios altamente dispersa. En este contexto, surge una cuestión central: ¿en qué medida los inmuebles se encuentran adecuadamente valuados y cuáles son los factores que influyen de manera más significativa en la determinación de su precio dentro del mercado actual?

La estimación del valor de un inmueble es un problema central en economía urbana y análisis financiero. Los modelos hedónicos han sido tradicionalmente utilizados para modelar el precio como función de atributos estructurales y de localización.

El presente trabajo se enfoca en la estimación del valor exclusivamente en **departamentos**. La base original incluía lofts, penthouse y pentgarden; sin embargo, dichos segmentos fueron excluidos para reducir heterogeneidad estructural y evitar segmentación implícita del mercado.

II. Análisis Exploratorio de Datos

Se recopiló una muestra de 210 departamentos ubicados en complejos residenciales de la zona norte de Mérida, Yucatán, incluyendo desarrollos en Temozón Norte, Dzityá, Santa Gertrudis Copó, Cholul y Paseos del Norte.

Para cada inmueble se consideraron como variables explicativas la superficie total en metros cuadrados (M2), el número de recámaras, el número de baños, el número de espacios de estacionamiento y el número de amenidades disponibles dentro del desarrollo.

Adicionalmente, se incorporaron variables indicadoras (dummy) de ubicación con el objetivo de capturar efectos espaciales diferenciales en la determinación del precio.

	M2	Rec	Baños	Est	Amen	Precio
Media	87.48	1.81	1.68	1.40	9.79	3,553,681
Desv.	44.02	0.77	0.60	0.59	5.60	1,955,424
Min	40.60	1	1	0	0	1,345,000
P50	80.00	2	2	1	8	3,166,318
Max	282.41	3	3	3	23	11,395,000

Cuadro I
Estadísticas descriptivas de departamentos

Se observa alta dispersión en la variable precio, lo cual sugiere posible asimetría y presencia de valores extremos.

III. Metodología

III-A. División de Datos

Se dividió la muestra en 80 % entrenamiento y 20 % prueba utilizando:

$$train_test_split(test_size = 0{,}2, random_state = 42)$$

III-B. Modelo de Regresión Lineal

Se estimaron dos especificaciones:

1. Modelo en niveles:

$$Precio = \beta_0 + \sum_{i=1}^{k} \beta_i X_i + \epsilon$$

2. Modelo log-lineal:

$$\log(Precio) = \beta_0 + \sum_{i=1}^{k} \beta_i X_i + \epsilon$$

La transformación logarítmica permite interpretar coeficientes como efectos porcentuales y reduce heterocedasticidad.

III-C. Modelo Random Forest

Se estimó un modelo Random Forest con 200 árboles y profundidad máxima de 6:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^{B} T_b(X)$$

Este modelo permite capturar relaciones no lineales sin especificación funcional previa.

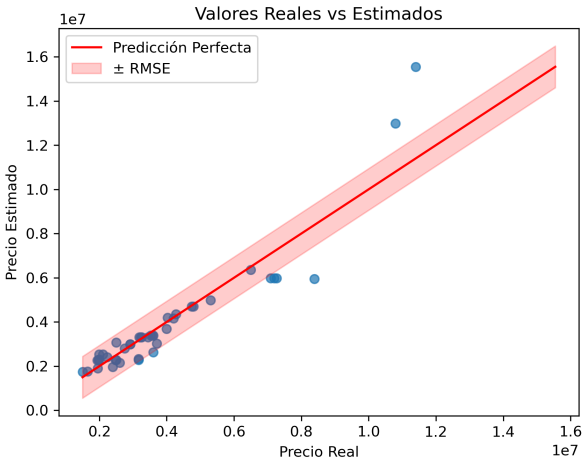

Figura 1. Valores reales vs estimados – Regresión Lineal

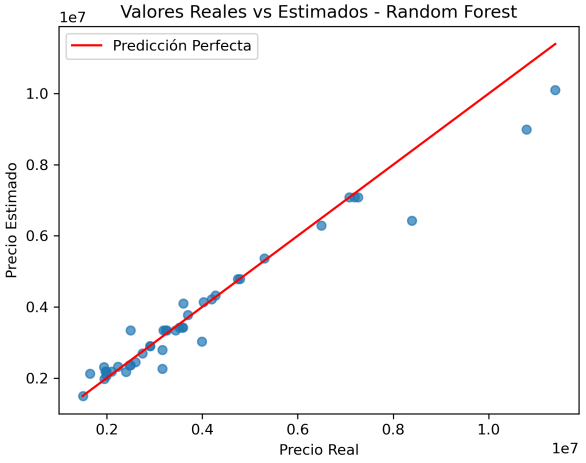

Figura 2. Valores reales vs estimados – Random Forest

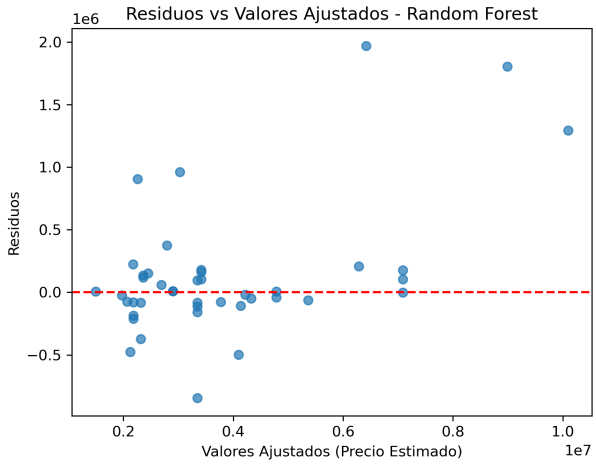

Figura 3. Residuos vs valores ajustados – Random Forest

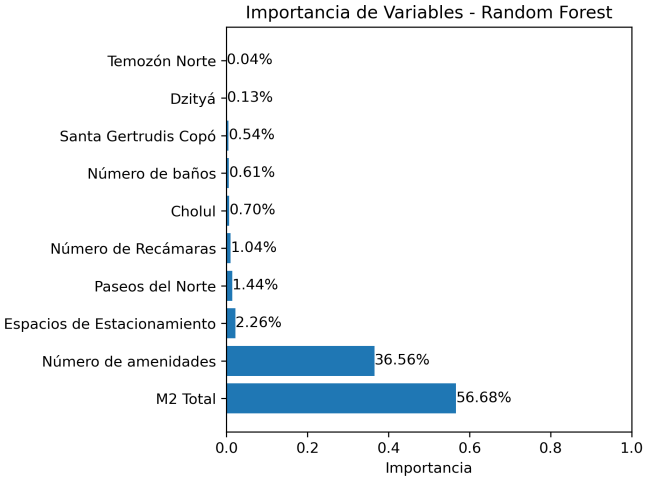

Figura 4. Importancia de variables – Random Forest

IV. Resultados

Modelo	MAE	RMSE	R^2
Regresión Lineal (log)	534,128	942,138	0.829
Random Forest	300,754	544,720	0.942

Cuadro II
Comparación de desempeño

El mercado inmobiliario de departamentos en el norte de Mérida presenta relaciones no lineales entre características estructurales y precio, lo cual se inclina al uso de modelos no paramétricos como Random Forest.

V. Discusión

Los resultados muestran diferencias sustanciales en el desempeño de los modelos estimados. El modelo Random Forest supera ampliamente a la regresión lineal logarítmica en todas las métricas evaluadas. El error absoluto medio se reduce de 534,128 a 300,754 pesos, lo que representa una mejora cercana al 43 %. Asimismo, el coeficiente de determinación aumenta de 0.829 a 0.942, indicando que el modelo basado en árboles explica una mayor proporción de la variabilidad observada en los precios.

Estos resultados sugieren la presencia de relaciones no lineales e interacciones entre las variables estructurales y la localización. Mientras que la regresión lineal impone una estructura funcional aditiva y efectos constantes, Random Forest permite capturar umbrales, segmentaciones implícitas y efectos diferenciados según combinaciones específicas de características.

El análisis de residuos muestra ausencia de patrones sistemáticos fuertes, aunque se observa mayor dispersión en

el segmento de mayor valor, lo cual es consistente con la naturaleza heterocedástica del mercado inmobiliario, donde el error absoluto tiende a crecer proporcionalmente con el nivel de precio.

Es importante señalar que la menor contribución lineal de las variables de localización no implica que la ubicación carezca de relevancia económica. Dado que la muestra se compone exclusivamente de departamentos situados en la zona norte de Mérida, Yucatán, la variabilidad espacial entre observaciones es relativamente acotada. En consecuencia, las diferencias de precio atribuibles a la localización dentro de esta misma zona pueden no manifestarse como efectos estrictamente aditivos y constantes, como supone la regresión lineal.

Más bien, la evidencia sugiere que el impacto de la ubicación dentro de la zona norte podría interactuar con características estructurales específicas del inmueble, tales como superficie o número de amenidades. Este comportamiento no lineal es capturado con mayor flexibilidad por el modelo Random Forest, lo cual contribuye a explicar su mejor desempeño predictivo.

VI. Conclusiones

El presente estudio demuestra que la estimación del valor de departamentos, para el mercado inmobiliario, puede beneficiarse significativamente del uso de modelos de aprendizaje automático. Si bien la regresión lineal logarítmica ofrece una estructura interpretativa clara y mejora el comportamiento estadístico respecto al modelo en niveles, su capacidad predictiva se ve limitada por la imposición de relaciones estrictamente aditivas y lineales entre las variables explicativas y el precio.

Por su parte, el modelo Random Forest presenta un desempeño sustancialmente superior, reduciendo el error absoluto medio y aumentando el coeficiente de determinación hasta niveles cercanos al 94 %. Este resultado confirma la existencia de patrones no lineales e interacciones entre características estructurales y atributos espaciales dentro del mercado inmobiliario analizado.

La evidencia empírica sugiere que la superficie total y el número de amenidades constituyen determinantes fundamentales del precio, mientras que las variables de localización, aunque económicamente relevantes, presentan menor variabilidad explicativa dentro de una zona geográfica relativamente homogénea como la zona norte de Mérida.

Desde una perspectiva aplicada, los resultados indican que los modelos no paramétricos pueden funcionar como herramientas robustas para la valuación automatizada de inmuebles, especialmente en mercados con alta dispersión de precios y presencia de efectos no lineales. No obstante, el tamaño de muestra y la concentración geográfica del análisis representan limitaciones que deben considerarse.

Como líneas futuras de investigación, se sugiere ampliar la base de datos incorporando otras zonas de la ciudad, incluir variables macroeconómicas y de entorno urbano, así como la exploración de técnicas adicionales o modelos híbridos.